

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。
评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 1（英文表达 → 中文）

Reference:

英文源表达。translation_en

待评估句:

模型给出的中文翻译。translation_zh

评估目标:

判断模型是否把英文表达准确、自然地翻译成中文，并判断中文输出中是否形成了合格的中文成语表达。

如果is_invalid_zh=True，所有评估都是NA

一、Code-Switching（1--5分）

评估待评估句是否避免不必要的英文、拼音或其他非中文成分。

1分：完全不是中文。

2分：大部分不是中文，或严重混合英文/拼音/其他语言。

3分：有明显混合，但仍包含较多中文内容。

4分：基本是中文，只有少量非中文成分。

5分：完全是中文，没有不必要的非中文成分。

二、Grammar（1--5分）

评估中文语言形式是否正确、通顺。

1分：语言结构严重错误。

3分：部分结构成立，但有明显问题。

5分：中文结构完整、正确。

三、Fluency（1--5分）

评估中文是否自然、流畅、可接受。

1分：非常不自然。

3分：可以理解，但明显生硬或别扭。

5分：非常自然、流畅。

四、Adequacy（1--5分）

评估中文是否保留了英文源表达的核心意义。

1分：核心意义基本丢失或错误。

3分：大致表达了一部分意义，但不完整或不准确。

5分：准确、完整地表达了核心意义。

五、Idiom Form (1--5分)

评估中文输出是否包含形式合格的中文习惯表达或成语。这里暂时不判断该成语意义是否与 source 完全匹配，只判断表达形式。

1分：没有中文习惯表达或固定表达。例如：做了不必要的事情。

2分：有中文固定表达或口语化习惯表达，但不是标准成语。例如：没事找事。

3分：像成语，但属于错误、编造或可疑表达。例如：画足添蛇。

4分：是有效的中文成语，但不是标准四字成语。例如：金玉其外，败絮其中。

5分：是有效的标准四字成语。例如：画蛇添足。