

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。
评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 2 C3（英文句子 → 中文句子，要求使用指定目标成语）

Reference:

英文源句子（translation_en），以及系统提供的指定目标成语（target_idiom）。

待评估句：

模型给出的中文翻译句子。（translation_zh）

评估目标：

判断模型是否准确、自然地翻译英文句子，并判断它是否准确使用了指定目标成语。这里重点不是“是否用了某个成语”，而是“是否按要求原样使用指定成语，并且自然、合理地融入句子”。

如果is_invalid_zh = True, 则评估结果都是NA

一、Code-Switching（1--5分）

评估待评估句是否避免不必要的英文、拼音或其他非中文成分。

1分：完全不是中文。

2分：大部分不是中文，或严重混合英文/拼音/其他语言。

3分：有明显混合，但仍包含较多中文内容。

4分：基本是中文，只有少量非中文成分。

5分：完全是中文，没有不必要的非中文成分。

二、Grammar（1--5分）

评估中文语法是否正确。

1分：语法严重错误。

3分：部分语法正确，但有明显错误。

5分：语法完整、正确。

三、Fluency（1--5分）

评估中文是否自然、流畅、符合中文表达习惯。

1分：非常不自然。

3分：可以理解，但明显生硬或别扭。

5分：非常自然、流畅。

四、Adequacy（1--5分）

评估中文输出是否保留了英文源句子的整体意义。

1分：整句意义基本丢失或错误。

3分：大致表达了部分句意，但不完整或不准确。

5分：准确、完整地表达了整句意义。

五、Target Idiom Use (1--5分)

评估指定目标成语是否被原样包含，并且是否自然融入中文翻译，同时不破坏英文源句的意义。

1分：指定目标成语缺失、被改写、机械插入，或没有真正融入句子。

2分：指定目标成语被包含，但使用不自然，或严重扭曲英文源句意义。

3分：指定目标成语被包含，并且有一定整合，但使用生硬、动机较弱，或与句意联系较松散。

4分：指定目标成语被包含，并且基本自然融入句子，只存在轻微自然度或语义贴合问题。

5分：指定目标成语被原样包含，自然融入句子，并且与中文翻译语境恰当匹配。