

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。

评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 2（包含成语的中文句子 → 英文）

Reference:

原始中文句子，其中包含一个中文成语。sentence

待评估句:

模型给出的英文翻译句子。translation_en

评估目标:

判断模型是否准确、自然地翻译整句中文，并特别判断原句中成语承载的意义是否在英文中得到保留。

如果 is_invalid_en=True, 所有评估都是 NA

一、Code-Switching (1--5 分)

评估待评估句是否避免不必要的中文、拼音或其他非英文成分。

1 分：完全不是英文。

2 分：大部分不是英文，或严重混合中文/拼音/其他语言。

3 分：有明显混合，但仍包含较多英文内容。

4 分：基本是英文，只有少量非英文成分。

5 分：完全是英文，没有不必要的非英文成分。

二、Grammar (1--5 分)

评估英文语法是否正确。

1 分：语法严重错误，难以理解。

3 分：部分语法正确，但有明显错误。

5 分：语法完整、正确。

三、Fluency (1--5 分)

评估英文表达是否自然、流畅、符合英语习惯。

1 分：非常不自然。

3 分：可以理解，但明显生硬或别扭。

5 分：非常自然、流畅。

四、Adequacy (1--5 分)

评估英文是否保留了原始中文句子的整体意义。

1 分：整句意义基本丢失或错误。

3 分：大致表达了部分句意，但不完整或不准确。

5 分：准确、完整地表达了整句意义。

五、Idiom-related Meaning Translation (1--5 分)

评估原中文成语在句中承载的意义是否被英文翻译出来。

1 分：成语相关意义完全没有表达，或严重误译。

3 分：成语相关意义部分表达，但不完整或不准确。

5 分：成语相关意义被准确、恰当地表达出来。