

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。

评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 2 C1（中文句子 → 英文 → 中文自然句）

Reference：

原始中文句子，其中包含一个中文成语。(sentence)

待评估句：

模型最终回译得到的中文句子。(translation_zh)

评估目标：

判断经过英文中转后，最终中文句子是否保留原始中文句子的整体意义，并判断原成语相关意义是否得到保留。该任务不强制要求最终输出使用成语，但需要记录是否出现成语。

一、Code-Switching（1--5 分）

评估待评估句是否避免不必要的英文、拼音或其他非中文成分。

1 分：完全不是中文。

2 分：大部分不是中文，或严重混合英文/拼音/其他语言。

3 分：有明显混合，但仍包含较多中文内容。

4 分：基本是中文，只有少量非中文成分。

5 分：完全是中文，没有不必要的非中文成分。

二、Grammar（1--5 分）

评估中文语法是否正确。

1 分：语法严重错误。

3 分：部分语法正确，但有明显错误。

5 分：语法完整、正确。

三、Fluency (1--5 分)

评估中文是否自然、流畅、符合中文表达习惯。

1 分：非常不自然。

3 分：可以理解，但明显生硬或别扭。

5 分：非常自然、流畅。

四、Adequacy (1--5 分)

评估最终中文输出是否保留了原始中文句子的整体意义。

1 分：整句意义基本丢失或错误。

3 分：大致表达了部分句意，但不完整或不准确。

5 分：准确、完整地表达了整句意义。

五、Idiom-related Meaning Preservation (1--5 分)

评估原始中文成语在句中承载的意义是否在最终中文输出中得到保留。注意：这里不要求一定使用成语。

1 分：成语相关意义完全没有保留，或严重扭曲。

3 分：成语相关意义部分保留，但不完整或不准确。

5 分：成语相关意义被准确、恰当地保留下来。

六、Idiom Use (分类标签)

I0：最终中文输出中没有使用成语。

I1：最终中文输出中至少使用了一个成语。