

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。

评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 2 C3（中文句子 → 英文 → 中文句子，要求使用指定目标成语）

Reference：

原始中文句子(sentence)，以及系统提供的指定目标成语(target_idiom)。通常该目标成语就是原始中文句子中的成语。

待评估句：

模型最终回译得到的中文句子。(translation_zh)

评估目标：

判断经过英文中转后，最终中文句子是否保留原始句子的整体意义，并判断指定目标成语是否被原样、自然、合理地重新整合进最终中文句子中。

一、Code-Switching（1--5 分）

评估待评估句是否避免不必要的英文、拼音或其他非中文成分。

1 分：完全不是中文。

2 分：大部分不是中文，或严重混合英文/拼音/其他语言。

3 分：有明显混合，但仍包含较多中文内容。

4 分：基本是中文，只有少量非中文成分。

5 分：完全是中文，没有不必要的非中文成分。

二、Grammar (1--5 分)

评估中文语法是否正确。

1 分：语法严重错误。

3 分：部分语法正确，但有明显错误。

5 分：语法完整、正确。

三、Fluency (1--5 分)

评估中文是否自然、流畅、符合中文表达习惯。

1 分：非常不自然。

3 分：可以理解，但明显生硬或别扭。

5 分：非常自然、流畅。

四、Adequacy (1--5 分)

评估最终中文输出是否保留了原始中文句子的整体意义。

1 分：整句意义基本丢失或错误。

3 分：大致表达了部分句意，但不完整或不准确。

5 分：准确、完整地表达了整句意义。

五、Target Idiom Use (1--5 分)

评估指定目标成语是否被原样包含，并且是否自然地重新融入最终中文句子，同时恰当地保留其在原始中文输入中的相关意义和功能。

1 分：指定目标成语缺失、被改写、机械插入，或没有真正融入句子。

2 分：指定目标成语被包含，但使用不自然、与原始中文输入语义不合，或严重扭曲原意。

3 分：指定目标成语被包含，并且有一定整合，但使用生硬、动机较弱，或只与原句语境松散相关。

4 分：指定目标成语被包含，并且基本自然融入句子，只存在轻微自然度、语义贴合或语境功能问题。

5 分：指定目标成语被原样包含，自然重新融入句子，并且恰当地保留其在原始中文输入中的相关意义和功能。