

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。

评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 1（中文成语 → 英文）

Reference:

原始中文成语。source_idiom

待评估句:

模型给出的英文翻译。translation_en

如果 is_invalid_en=True, 所有评估都是 NA

评估目标:

判断模型是否把中文成语准确、自然、恰当地翻译成英文表达。

一、Code-Switching (1--5 分)

评估待评估句是否避免不必要的中文、拼音或其他非英文成分。

1 分：完全不是英文。

2 分：大部分不是英文，或严重混合中文/拼音/其他语言。

3 分：有明显混合，但仍包含较多英文内容。

4 分：基本是英文，只有少量非英文成分。

5 分：完全是英文，没有不必要的非英文成分。

二、Grammar (1--5 分)

评估英文语法是否正确。

1 分：语法严重错误，难以理解。

3 分：部分语法正确，但有明显错误。

5 分：语法完整、正确。

三、Fluency (1--5 分)

评估英文表达是否自然、流畅、符合英语习惯。

1 分：非常不自然。

3 分：可以理解，但明显生硬或别扭。

5 分：非常自然、流畅。

四、Adequacy (1--5 分)

评估英文是否保留了原中文成语的核心意义。

1 分：核心意义基本丢失或错误。

3 分：大致表达了一部分意义，但不完整或不准确。

5 分：准确、完整地表达了核心意义。

五、English Rendering Strategy (1--5 分)

评估中文成语被翻译成英文时采用的表达策略是否恰当，重点看它是生硬直译、解释性翻译，还是自然的英语习语/文化等值表达。

1 分：表达不清楚或无效。例如：画蛇添足 → snake foot painting。

2 分：过度直译或很生硬。例如：画蛇添足 → draw a snake and add feet to it。

3 分：有部分意义，但过于笼统或不完整。例如：画蛇添足 → do extra things。

4 分：自然、准确的解释性翻译。例如：画蛇添足 → do something unnecessary and make it worse。

5 分：自然的英语习语或文化等值表达。例如：画蛇添足 → gild the lily。