

人工标注说明

请你根据给定的 reference 和待评估句，对待评估句进行人工评分。

评分必须使用整数 1--5，除非某一项明确是分类标签。

任务：Task 2 C2（中文句子 → 英文 → 中文句子，要求重新引入成语）

Reference:

原始中文句子，其中包含一个中文成语。(sentence)

待评估句:

模型最终回译得到的中文句子。(translation_zh)

评估目标:

判断经过英文中转后，最终中文句子是否保留原始句子的整体意义，并判断模型是否能灵活地重新引入一个合适的中文成语。这里不要求重新引入的成语必须与原始成语完全相同，只要它语义合适、自然融入句子即可。

一、Code-Switching (1--5 分)

评估待评估句是否避免不必要的英文、拼音或其他非中文成分。

1 分：完全不是中文。

2 分：大部分不是中文，或严重混合英文/拼音/其他语言。

3 分：有明显混合，但仍包含较多中文内容。

4 分：基本是中文，只有少量非中文成分。

5 分：完全是中文，没有不必要的非中文成分。

二、Grammar (1--5 分)

评估中文语法是否正确。

1 分：语法严重错误。

3 分：部分语法正确，但有明显错误。

5 分：语法完整、正确。

三、Fluency (1--5 分)

评估中文句子是否自然、流畅。

1 分：非常不自然。

3 分：可以理解，但明显生硬或别扭。

5 分：非常自然、流畅。

四、Adequacy (1--5 分)

评估最终中文输出是否准确保留原始中文输入句子的整体意义。

1 分：整句意义基本丢失或错误。

3 分：大致表达了部分句意，但不完整或不准确。

5 分：准确、完整地表达了整句意义。

五、Idiom Reintroduction (1--5 分)

评估输出是否成功重新引入了一个有效的中文成语，以及该成语本身是否恰当地表达了原始中文输入句子的相关意义。重新引入的成语不必与原始成语完全相同，但应语义合适、自然融入句子。

1 分：没有包含有效中文成语，或包含的表达不是中文成语。

2 分：包含中文成语，但该成语与原始中文输入语义无关，或只是机械插入。

3 分：包含中文成语，且与原始中文输入有一定关系，但使用生硬、动机较弱，或只松散相关。

4 分：包含有效中文成语，并基本表达了原始中文输入中的相关意义，只存在轻微自然度或语义精确性问题。

5 分：包含有效中文成语，成语自然融入句子，并准确表达了原始中文输入中的相关意义。